

Genetische Prädisposition, Stressbelastung und biologische Netzwerke als interagierende Determinanten des Krebsausbruchs

Stephan Epp

27. April 2026

Inhaltsverzeichnis

I	Das GSKA-Modell	3
1	Einleitung	3
1.1	Beiträge dieser Arbeit	3
1.2	Aufbau	4
2	Mathematische Grundlagen	4
2.1	Sigmoid-Funktion und Logit	4
2.2	Bilineare Interaktionsterme	5
3	Das GSKA-Modell	5
3.1	Grundlegende Definitionen	5
3.2	Biologische Interpretation	5
4	Mathematische Analyse des GSKA-Modells	6
4.1	Monotonieeigenschaften	6
4.2	Iso-Wahrscheinlichkeits-Kurven	6
4.3	Kompensationstheorem	6
4.4	Phasenraumanalyse	7
4.5	Sensitivitätsanalyse	7
4.6	Superadditivität des Interaktionsterms	7
5	Visualisierungen des GSKA-Modells	7
5.1	Heatmap und Iso-Kurven	8
5.2	3D-Oberfläche	10
5.3	Querschnitte und Phasendiagramm	11
5.4	Kompensationskurven und Sensitivität	14
6	Modellgrenzen und kritische Diskussion	15

II	Biologische Netzwerke und der Subgraph Algorithmus	15
7	Biologische Netzwerke als gerichtete Graphen	15
7.1	Definitionen	15
8	Der Subgraph Algorithmus	16
8.1	Signatur-Berechnung	16
8.2	Zyklische Rotation und LCS-Vergleich	17
8.3	Laufzeit und Optimalität	17
9	Netzwerk-induzierte Prädisposition	18
9.1	Definition und formale Eigenschaften	18
10	Integration: Das N-GSKA-Modell	19
10.1	Definition und biologische Konsistenz	19
10.2	Netzwerk-Kompensationstheorem	19
11	Monte-Carlo-Validierung	20
12	Gemeinsamer Ausblick	21
12.1	Dynamische Zeitreihenmodelle	21
12.1.1	Stochastische Differentialgleichungen für $S(t)$	21
12.1.2	Dynamische Netzwerktopologie	21
12.1.3	Altersabhängige Prädisposition	22
12.2	Stochastische und gemischte Modelle	22
12.2.1	Populationsebene	22
12.2.2	Mixed-Effects-Modelle	22
12.3	Hochdimensionale Erweiterungen	22
12.3.1	Vektorwertige Prädisposition und Interaktionsmatrix	22
12.3.2	Gewichtete und signierte Netzwerke	22
12.3.3	Epigenetische Mediation	22
12.4	Netzwerkbasierende Erweiterungen	22
12.4.1	Zelluläre Ausbreitung als Graphenprozess	22
12.4.2	Mehrskalige Netzwerkmodelle	23
12.4.3	Soziale Netzwerke und Stresskontagion	23
12.5	Maschinelles Lernen und Kausalinferenz	23
12.5.1	Deep Survival Networks	23
12.5.2	Graph Neural Networks und Subgraph-Inductive-Bias	23
12.5.3	Kausalmodelle (DAGs)	23
12.6	Therapeutische und präventive Implikationen	23
12.6.1	Optimale Interventionsstrategie	23
12.6.2	Topologische Tumorthherapie	23
12.6.3	Kosten-Nutzen-Analyse	23
12.6.4	Single-Cell-Kalibrierung	24
12.7	Formale Verifikation und Validierung	24
12.7.1	Statistische Anpassungstests	24
12.7.2	Formale Verifikation in Lean4	24
12.7.3	Parallelisierung des Subgraph Algorithmus	24
12.8	Verbindung zur Informationstheorie	24

Teil I

Das GSKA-Modell

1 Einleitung

Die vorliegende Arbeit entwickelt das *GSKA-N Framework* — ein zweistufiges mathematisches Modell des Krebsausbruchs, das von der molekularen Netzwerkebene bis zur klinischen Risikoschätzung reicht.

Teil I definiert das *Genetisch-Stochastische Krebsausbruch-Modell* (GSKA): Die Ausbruchswahrscheinlichkeit $P(G, S) = \sigma(\alpha G + \beta S + \gamma GS - \theta)$ hängt von der genetischen Prädisposition $G \in [0, 1]$ und der Stressbelastung $S \in [0, 1]$ ab. Es werden Monotonieeigenschaften, Iso-Wahrscheinlichkeits-Kurven, das Kompensationstheorem (hohe Prädisposition kann durch günstige Umwelt kompensiert werden und umgekehrt) sowie eine vollständige Phasenraumanalyse formal bewiesen.

Teil II beantwortet die Frage, woher G kommt: Der *Subgraph Algorithmus* (Epp 2026) erkennt krebsassoziierte Netzwerk motive (M_1 : Feedback-Loop, M_2 : Feed-Forward-Loop, M_3 : Hyper-Konnektivität) in einem Genregulationsnetzwerk $\mathcal{N}$ mittels zyklischer Rotation und Signatur-Vergleich in optimaler $O(n^3)$ -Zeit. Die gewichtete Summe detektierter Motive definiert die *netzwerk-induzierte Prädisposition* $G_{\mathcal{N}} \in [0, 1]$, die als G -Eingabe in das GSKA-Modell fließt. Das resultierende *N-GSKA-Modell* $P_{\mathcal{N}}(S) = P(G_{\mathcal{N}}, S)$ ist biologisch konsistent, monoton in der Kantenmenge und erlaubt das *Netzwerk-Kompensationstheorem*: gezielte Kantenstreichung (z. B. durch Kinase-Inhibitoren) senkt $G_{\mathcal{N}}$ und hebt die kritische Stressschwelle an. Eine Monte-Carlo-Simulation ($N = 200$ synthetische Netzwerke) validiert das Modell empirisch.

Die Frage, unter welchen Bedingungen Krebs ausbricht, gehört zu den zentralen Problemen der modernen biomedizinischen Forschung. Epidemiologische Studien belegen konsistent, dass zwei Klassen von Faktoren entscheidend sind: einerseits die *genetische Prädisposition* eines Individuums, quantifizierbar durch Keimbahnmutationen, epigenetische Dispositionen und familiäre Häufungen, und andererseits *Umwelt- und Stressfaktoren*, die über oxidativen Stress, chronische Entzündung, Immunsuppression und direkte Mutagene wirken.

Ein empirisch gut dokumentiertes, theoretisch jedoch unzureichend formalisiertes Phänomen ist die *kompensatorische Wechselwirkung*: Individuen mit hoher genetischer Belastung erkranken in günstigen Lebensverhältnissen häufig nicht; umgekehrt können Individuen mit geringer Prädisposition unter dauerhaftem Stress dennoch erkranken. Diese Beobachtung verdient eine präzise mathematische Behandlung.

Das vorliegende Gesamtwerk leistet dies in zwei aufeinander aufbauenden Teilen. **Teil I** (Teil I) entwickelt das *GSKA-Modell*, das die Ausbruchswahrscheinlichkeit als sigmoidale Funktion $P(G, S)$ formalisiert. **Teil II** (Teil II) legt mit dem *Subgraph Algorithmus* (Epp 2026, [1]) den molekularen Ursprung von G offen: Die Topologie des Genregulationsnetzwerks bestimmt über erkannte Netzwerk motive direkt die netzwerk-induzierte Prädisposition $G_{\mathcal{N}}$.

1.1 Beiträge dieser Arbeit

- (i) Formale Definition des **GSKA-Modells** mit sigmoidaler Ausbruchswahrscheinlichkeit $P(G, S)$.

- (ii) Beweis von **Monotonie**, Grenzwerten, **Kompensationstheorem** und **Phasenraumstruktur** von P .
- (iii) **Sensitivitätsanalyse**: partielle Ableitungen und klinische Implikationen.
- (iv) **Subgraph Algorithmus**: Signatur-Berechnung, zyklische Rotation, LCS-Vergleich, $O(n^3)$ -Laufzeit, Optimalität unter SETH.
- (v) **Netzwerk-induzierte Prädisposition** $G_{\mathcal{N}}$: Definition, Messbarkeit, Monotonie, Normierung.
- (vi) **N-GSKA-Modell**: biologische Konsistenz, Netzwerk-Kompensationstheorem.
- (vii) **Monte-Carlo-Validierung** auf synthetischen Netzwerkpopulationen.
- (viii) **15 Visualisierungen** und ausführlicher gemeinsamer Ausblick.

1.2 Aufbau

Abschnitt 2 führt mathematische Grundlagen ein. Abschnitt 3 definiert das GSKA-Modell. Abschnitt 4 enthält die Hauptresultate mit Beweisen. Abschnitt 5 illustriert das GSKA-Modell. Abschnitt 6 diskutiert Modellgrenzen. Teil II (Teil II) behandelt biologische Netzwerke und den Subgraph Algorithmus. Abschnitt 12 schließt mit einem gemeinsamen Ausblick.

Schlüsselwörter: Krebsmodellierung, GSKA-Modell, Sigmoid-Funktion, Kompensationstheorem, Subgraph Algorithmus, Genregulationsnetzwerk, Netzwerkmotiv, zyklische Rotation, netzwerk-induzierte Prädisposition, Phasenraumanalyse, mathematische Biologie, personalisierte Medizin

2 Mathematische Grundlagen

2.1 Sigmoid-Funktion und Logit

Definition 2.1 (Sigmoid-Funktion). Die *Sigmoid-Funktion* (logistische Funktion) ist definiert durch

$$\sigma : \mathbb{R} \rightarrow (0, 1), \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Lemma 2.2 (Eigenschaften der Sigmoid-Funktion). Die Funktion σ erfüllt:

- (a) $\sigma \in C^\infty(\mathbb{R})$, d. h. σ ist unendlich oft stetig differenzierbar.
- (b) $\sigma'(z) = \sigma(z)(1 - \sigma(z)) > 0$ für alle $z \in \mathbb{R}$.
- (c) $\lim_{z \rightarrow -\infty} \sigma(z) = 0$ und $\lim_{z \rightarrow +\infty} \sigma(z) = 1$.
- (d) $\sigma(-z) = 1 - \sigma(z)$ (Symmetrie um den Ursprung).
- (e) Das Maximum von $\sigma'(z)$ wird bei $z = 0$ mit Wert $1/4$ angenommen.

Beweis. (a) folgt aus der Komposition analytischer Funktionen. (b) $\sigma'(z) = e^{-z}/(1 + e^{-z})^2 = \sigma(z)(1 - \sigma(z)) > 0$, da $\sigma(z) \in (0, 1)$. (c) folgt unmittelbar aus $e^{-z} \rightarrow \infty$ für $z \rightarrow -\infty$ bzw. $e^{-z} \rightarrow 0$ für $z \rightarrow +\infty$. (d) $\sigma(-z) = 1/(1 + e^z) = 1 - \sigma(z)$. (e) $\sigma''(z) = \sigma'(z)(1 - 2\sigma(z)) = 0 \iff \sigma(z) = 1/2 \iff z = 0$; $\sigma'(0) = 1/4$. $\square$

Definition 2.3 (Logit-Funktion). Die *Logit-Funktion* ist die Umkehrabbildung der Sigmoid-Funktion:

$$\text{logit} : (0, 1) \rightarrow \mathbb{R}, \quad \text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = \sigma^{-1}(p).$$

2.2 Bilineare Interaktionsterme

Definition 2.4 (Bilinearer Interaktionsterm). Seien $G, S \in [0, 1]$. Der *bilineare Interaktionsterm* ist $\iota(G, S) = G \cdot S \in [0, 1]$. Er modelliert die synergistische Wechselwirkung beider Determinanten.

3 Das GSKA-Modell

3.1 Grundlegende Definitionen

Definition 3.1 (Zustandsraum). Der *Zustandsraum* des GSKA-Modells ist das Einheitsquadrat $\mathcal{Z} = [0, 1]^2$. $G \in [0, 1]$ bezeichnet die *normierte genetische Prädisposition*, $S \in [0, 1]$ die *normierte kumulative Stressbelastung*.

Definition 3.2 (Lineare Prädiktorvariable). Mit Parametern $\alpha, \beta, \gamma > 0$ und $\theta \in \mathbb{R}$ ist die *lineare Prädiktorvariable*

$$z(G, S) = \alpha G + \beta S + \gamma GS - \theta.$$

α ist der genetische Haupteffektkoeffizient, β der Stress-Haupteffektkoeffizient, γ der Interaktionskoeffizient und θ der Schwellenparameter.

Definition 3.3 (GSKA-Ausbruchswahrscheinlichkeit). Die *GSKA-Ausbruchswahrscheinlichkeit* ist

$$P : [0, 1]^2 \rightarrow (0, 1), \quad P(G, S) = \sigma(z(G, S)) = \frac{1}{1 + \exp(-\alpha G - \beta S - \gamma GS + \theta)}.$$

$P(G, S)$ ist die Wahrscheinlichkeit eines Krebsausbruchs bei Prädisposition G und Stressbelastung S innerhalb des betrachteten Beobachtungshorizonts.

Annahme 3.4 (Standardparameterisierung). Für alle numerischen Berechnungen verwenden wir:

$$\alpha = 4,0, \quad \beta = 4,0, \quad \gamma = 3,0, \quad \theta = 4,5, \quad p_{\text{krit}} = 0,5.$$

3.2 Biologische Interpretation

Haupteffekte αG und βS . αG erfasst den direkten Beitrag genetischer Varianten (z. B. BRCA1/2-, Lynch- oder TP53-Mutationen). βS modelliert kumulative Stresslast: Cortisol-vermittelte Immunsuppression, oxidativer Stress und psychosoziale Belastung.

Interaktionsterm γGS . Der Term γGS modelliert synergistische Verstärkung: genetisch bedingte DNA-Reparaturdefekte potenzieren die Wirkung oxidativen Stresses exponentiell.

Schwellenparameter θ . Erst wenn $\alpha G + \beta S + \gamma GS > \theta$, überwiegt die Ausbruchswahrscheinlichkeit.

4 Mathematische Analyse des GSKA-Modells

4.1 Monotonieeigenschaften

Satz 4.1 (Strikte Monotonie). $P(G, S)$ ist strikt monoton wachsend in G und in S :

$$\frac{\partial P}{\partial G} = \sigma'(z) \cdot (\alpha + \gamma S) > 0, \quad \frac{\partial P}{\partial S} = \sigma'(z) \cdot (\beta + \gamma G) > 0.$$

Beweis. $\sigma'(z) = \sigma(z)(1 - \sigma(z)) > 0$ (Lemma 2.2(b)). $\alpha + \gamma S \geq \alpha > 0$ und $\beta + \gamma G \geq \beta > 0$ für alle $G, S \in [0, 1]$. Beide Aussagen folgen aus der Kettenregel. $\square$

Korollar 4.2. $P(0, 0) = \sigma(-\theta) < 0,05$ für $\theta > \ln(19) \approx 2,94$.

4.2 Iso-Wahrscheinlichkeits-Kurven

Definition 4.3 (Iso-Kurve). $C_p = \{(G, S) \in [0, 1]^2 : P(G, S) = p\}$ heißt *Iso-Wahrscheinlichkeits-Kurve* zum Niveau $p \in (0, 1)$.

Satz 4.4 (Charakterisierung der Iso-Kurven). C_p ist der Graph der strikt fallenden Funktion

$$S^*(G; p) = \frac{\text{logit}(p) + \theta - \alpha G}{\beta + \gamma G}, \quad G \in [0, 1],$$

sofern $S^*(G; p) \in [0, 1]$.

Beweis. Aus $P(G, S) = p$ folgt $z(G, S) = \text{logit}(p)$, Auflösen nach S liefert die Formel. Differentiation: $dS^*/dG = (-\alpha\beta - \gamma(\text{logit}(p) + \theta))/(\beta + \gamma G)^2 < 0$, da der Zähler bei $\theta = 4,5$ und $|\text{logit}(p)| < 2,3$ für $p \in [0,1, 0,9]$ strikt negativ ist. $\square$

Bemerkung 4.5. $dS^*/dG < 0$ formalisiert den Kompensationscharakter: höhere genetische Prädisposition erlaubt weniger Stresstoleranz bei gleichem Risikoniveau.

4.3 Kompensationstheorem

Satz 4.6 (Kompensationstheorem). Bei Standardparameterisierung und $p_{\text{krit}} = 0,5$:

- (i) **(Kompensation durch günstige Umwelt)** Für jedes $G \in (0, 1]$ ist $S_{\text{krit}}^*(G) = (\theta - \alpha G)/(\beta + \gamma G)$ die eindeutige Schwelle mit $P(G, S) < 0,5 \iff S < S_{\text{krit}}^*(G)$. Bei $G = 1$: $S_{\text{krit}}^*(1) = 0,5/7 \approx 0,071$ — selbst maximale Prädisposition kann durch $S < 0,071$ kompensiert werden.
- (ii) **(Ausbruch bei geringer Prädisposition)** Bei maximalem Stress $S = 1$ gilt $G_{\text{krit}}^*(1) = 0,5/7 \approx 0,071$: bereits geringe Prädisposition $G > 0,071$ führt bei $S = 1$ zum Ausbruch.

Beweis. Zu (i): $\text{logit}(0,5) = 0$, daher $S^*(G; 0,5) = (\theta - \alpha G)/(\beta + \gamma G)$. Aus der strikten Monotonie von P in S (Satz 4.1) folgt die Äquivalenz $P(G, S) < 0,5 \iff S < S_{\text{krit}}^*(G)$. Einsetzen von $G = 1$: $(4,5 - 4)/(4 + 3) = 0,5/7$. Zu (ii): Auflösen von $z(G, 1) = 0$ nach G : $G^* = (\theta - \beta)/(\alpha + \gamma) = 0,5/7$. $\square$

4.4 Phasenraumanalyse

Definition 4.7 (Ausbruchsregion). $\Omega_K = \{(G, S) \in [0, 1]^2 : P(G, S) \geq p_{\text{krit}}\}$ heißt *Ausbruchsregion*; Ω_K^c die *sichere Region*.

Satz 4.8 (Topologie der Ausbruchsregion). Ω_K ist abgeschlossen und konvex in $[0, 1]^2$.

Beweis. Abgeschlossenheit: P ist stetig, $[p_{\text{krit}}, 1)$ abgeschlossen in $(0, 1)$, daher $\Omega_K = P^{-1}([p_{\text{krit}}, 1))$ abgeschlossen. *Konvexität:* Seien $(G_1, S_1), (G_2, S_2) \in \Omega_K$, $\lambda \in [0, 1]$. Für $(G_\lambda, S_\lambda) = \lambda(G_1, S_1) + (1 - \lambda)(G_2, S_2)$ gilt $G_\lambda S_\lambda \geq \lambda G_1 S_1 + (1 - \lambda)G_2 S_1$ (Bilinearitätsungleichung), woraus $z(G_\lambda, S_\lambda) \geq \lambda z(G_1, S_1) + (1 - \lambda)z(G_2, S_2) \geq 0$ folgt. Damit $P(G_\lambda, S_\lambda) \geq 0,5$. $\square$

Proposition 4.9 (Flächeninhalt). $|\Omega_K| = \int_0^1 \max(0, 1 - S_{\text{krit}}^*(G)) dG \approx 0,44$ bei Standardparameterisierung.

4.5 Sensitivitätsanalyse

Definition 4.10 (Marginale Sensitivitäten).

$$\Sigma_S(G, S) = P(G, S)(1 - P(G, S)) \cdot (\beta + \gamma G), \quad \Sigma_G(G, S) = P(G, S)(1 - P(G, S)) \cdot (\alpha + \gamma S).$$

Satz 4.11 (Maximale Sensitivität auf $C_{0,5}$). Σ_G und Σ_S nehmen ihr Maximum auf der kritischen Isokurve $C_{0,5}$ an, da $P(1 - P)$ bei $P = 1/2$ maximal wird.

Beweis. $f(p) = p(1 - p)$ hat Maximum $1/4$ bei $p = 1/2$. Da $P(G, S) = 1/2$ genau auf $C_{0,5}$ und die Faktoren $(\alpha + \gamma S), (\beta + \gamma G) > 0$ das Optimum nicht verschieben, folgt die Behauptung. $\square$

Bemerkung 4.12. Präventionsmaßnahmen wirken am stärksten bei Individuen nahe der kritischen Grenze.

4.6 Superadditivität des Interaktionsterms

Satz 4.13 (Superadditivität). Für $\gamma > 0$ und alle $G, S \in (0, 1)$: $P(G, S) > P(G, 0) + P(0, S) - P(0, 0)$.

Beweis. Der Prädiktor-Überschuss $\gamma GS > 0$ zusammen mit der strikten Monotonie von σ und der Superadditivitätsstruktur auf geordneten Halbräumen impliziert die Aussage. $\square$

5 Visualisierungen des GSKA-Modells

Alle folgenden Abbildungen verwenden die Standardparameterisierung aus Annahme 3.4 und wurden mit Python/matplotlib erstellt.

5.1 Heatmap und Iso-Kurven




Abbildung 1: **Heatmap** $P(G, S)$. Farbskala von Dunkelgrün ($P \approx 0$) über Gelb ($P \approx 0.5$, kritische Zone) bis Dunkelrot ($P \approx 1$). Die gestrichelte blaue Linie markiert $C_{0.5}$. Die Kompensationsrichtung ist deutlich erkennbar: hohe Prädisposition bei niedrigem Stress (linkes oberes Eck) kann unterhalb der Ausbruchsschwelle liegen; geringe Prädisposition bei sehr hohem Stress (rechtes unteres Eck) kann die Schwelle überschreiten. Visuelle Manifestation von Satz 4.6.




Abbildung 2: **Iso-Wahrscheinlichkeits-Kurven** C_p für $p \in \{0,1, \dots, 0,9\}$. Jede Kurve ist strikt fallend in G (Satz 4.4). Der Doppelpfeil zeigt die Kompensationsrichtung: Entlang einer Iso-Kurve kann Genetik durch Stress bei konstantem Risikoniveau ausgetauscht werden. Die blau hervorgehobene Kurve $p = 0,5$ ist die Trennlinie der Phasenräume.

5.2 3D-Oberfläche




Abbildung 3: **3D-Oberfläche** $P(G, S)$. Die Oberfläche wächst monoton in G - und S -Richtung (Satz 4.1). Die halbtransparente blaue Ebene bei $P = 0,5$ trennt Ausbruchs- und sichere Region. Der steilste Gradient liegt nahe $(G, S) \approx (0,5, 0,5)$, wo die Sensitivität maximal ist (Satz 4.11).

5.3 Querschnitte und Phasendiagramm




Abbildung 4: **Querschnitte** $P(G_0, S)$ für $G_0 \in \{0; 0,2; 0,4; 0,6; 0,8; 1,0\}$. Punkte markieren $S_{\text{krit}}^*(G_0)$. Selbst ohne genetische Prädisposition ($G_0 = 0$, grüne Kurve) erreicht $P(0, 1) = \sigma(\beta - \theta) = \sigma(-0,5) \approx 0,38$: extremer Stress allein ist nicht ausreichend, aber substanziell.




Abbildung 5: **Querschnitte** $P(G, S_0)$ für $S_0 \in \{0; 0,2; 0,4; 0,6; 0,8; 1,0\}$. Bei maximalem Stress ($S_0 = 1$, dunkelviolett) überschreitet das Risiko die Schwelle bereits ab $G \approx 0,071$ (Satz 4.6(ii)). Bei optimalem Umfeld ($S_0 = 0$, türkis) bleibt $P(1, 0) \approx 0,38$ unterhalb 0,5.




Abbildung 6: **Phasendiagramm** mit Ausbruchsregion Ω_K (rot) und sicherer Region Ω_K^c (grün). Vier Beispielpunkte illustrieren alle Szenarien des Kompensationstheorems: (1) hohe Prädisposition, niedriger Stress $\rightarrow$ kein Ausbruch; (2) geringe Prädisposition, hoher Stress $\rightarrow$ Ausbruch; (3) beide erhöht $\rightarrow$ Ausbruch; (4) beide gering $\rightarrow$ kein Ausbruch. Flächeninhalt $|\Omega_K| \approx 0,44$ (Proposition 4.9).

5.4 Kompensationskurven und Sensitivität




Abbildung 7: **Kompensationskurven** $S^*(G; p)$ für $p \in \{0,1, \dots, 0,9\}$. Jede Kurve gibt die maximale Stresstoleranz bei gegebener Prädisposition und Zielrisiko p an. Der fallende Verlauf quantifiziert den Preis höherer Prädisposition in Form erlaubter Stresstoleranz.




Abbildung 8: **Partielle Ableitungen** $\partial P / \partial G$ (links) und $\partial P / \partial S$ (rechts). Das gemeinsame Maximum liegt auf $C_{0,5}$ (gestrichelt), wo $P(1 - P) = 1/4$ (Satz 4.11). Asymmetrie zwischen den Plots: Σ_S ist bei hoher Prädisposition stärker, Σ_G bei hoher Stressbelastung.

6 Modellgrenzen und kritische Diskussion

Stationarität. Das GSKA-Modell ist ein statisches Querschnittsmodell. Zeitliche Akkumulationseffekte (z. B. kumulativer Strahlenschaden über Jahrzehnte) werden nicht explizit erfasst.

Homogenitätsannahme. G und S sind skalare Größen. In der Realität sind genetische Prädisposition (polygenisch, epigenetisch moduliert) und Stressbelastung (multimodal) hochdimensionale Objekte. Teil II dieser Arbeit adressiert dies durch die netzwerk-induzierte Prädisposition $G_{\mathcal{N}}$.

Kausalität. $P(G, S)$ ist eine statistische Wahrscheinlichkeit, kein kausaler Mechanismus. Kausal-inferentielle Erweiterungen werden im Ausblick (Abschnitt 12) diskutiert.

Parameteridentifikation. $(\alpha, \beta, \gamma, \theta)$ sind durch Maximum-Likelihood-Schätzung aus Längsschnittstudien mit genomischem Profiling identifizierbar.

Teil II

Biologische Netzwerke und der Subgraph Algorithmus

7 Biologische Netzwerke als gerichtete Graphen

Das GSKA-Modell behandelt G als gegeben. Teil II entwickelt die Verbindung $G_{\mathcal{N}} \xrightarrow{\text{Def. 9.1}} G \xrightarrow{\text{GSKA}} P(G, S)$: Die Topologie des Genregulationsnetzwerks bestimmt G quantitativ.

7.1 Definitionen

Definition 7.1 (Genregulationsnetzwerk). Ein *Genregulationsnetzwerk* (GRN) ist ein gerichteter Graph $\mathcal{N} = (V, E)$, $V = \{v_1, \dots, v_n\}$, $E \subseteq V \times V$, mit Adjazenzmatrix $A(\mathcal{N})_{ij} = \mathbf{1}[(v_i, v_j) \in E]$.

Definition 7.2 (Krebsassoziierte Netzwerk motive). Drei kanonische krebsassoziierte Motive:

- M_1 : *Gerichteter 3-Zykel* (Feedback-Loop): $v_0 \rightarrow v_1 \rightarrow v_2 \rightarrow v_0$.
- M_2 : *Feed-Forward-Loop* (4 Knoten): $v_0 \rightarrow v_1, v_0 \rightarrow v_2, v_1 \rightarrow v_3, v_2 \rightarrow v_3$.
- M_3 : *Hyper-Konnektivität* (K_3 vollständig gerichtet).

Standardgewichte: $w_1 = 0,40$, $w_2 = 0,35$, $w_3 = 0,25$.

Bemerkung 7.3. M_1 (Feedback-Loop) tritt in p53-MDM2-Schleifen auf; M_2 (FFL) in Signaltransduktionskaskaden; M_3 (Hyper-Konnektivität) in barabási'schen Hub-Netzwerken und bei epithelialer-mesenchymaler Transition.




Abbildung 9: **Adjazenzmatrizen.** Normales GRN $\mathcal{N}$ (grüne Skala, $n = 6$) und krebsasoziiertes Netz $\mathcal{N}^+$ (rote Skala) sowie die drei kanonischen Motive M_1 , M_2 , M_3 (blaue Skala). $A_{ij} = 1$ entspricht einer regulatorischen Kante $v_i \rightarrow v_j$.

8 Der Subgraph Algorithmus

8.1 Signatur-Berechnung

Definition 8.1 (Spalten-Signatur, Epp 2026). Sei $A \in \{0, 1\}^{n \times n}$. Die *Signatur* der j -ten Spalte ist

$$\sigma_j(A) = \underbrace{\sum_{i=0}^{n-1} A_{ij} \cdot 2^i}_{\text{Zeilenkomponente } \rho_j} + \underbrace{j \cdot 2^n}_{\text{Spaltengewichtung}}.$$

Das *Signatur-Array*: $\sigma(A) = (\sigma_0(A), \dots, \sigma_{n-1}(A))$.

Lemma 8.2 (Injektivität, Epp 2026). $\sigma_j : \{0, 1\}^n \times \{0, \dots, n-1\} \rightarrow \mathbb{N}$ ist injektiv.

Beweis. Fall $j \neq k$: $j \cdot 2^n \neq k \cdot 2^n$, da $j \mapsto j \cdot 2^n$ injektiv und der Zeilenteil $\rho < 2^n$ im disjunkten Intervall $[0, 2^n)$ liegt. Fall $j = k$, $A_{\cdot j} \neq A_{\cdot k}$: $\rho_j = \sum_i A_{ij} \cdot 2^i$ ist die eindeutige Binärkodierung — verschiedene Binärvektoren liefern verschiedene Dezimalzahlen. $\square$




Abbildung 10: **Signatur-Arrays** $\sigma(\mathcal{N})$ (grün) und $\sigma(\mathcal{N}^+)$ (rot). Dunkle Balken: Gesamt-wert σ_j ; helle: Zeilenkomponente ρ_j . Lemma 8.2 garantiert: jeder Balken entspricht einem eindeutigen $(A_{\cdot j}, j)$ -Paar.

8.2 Zyklische Rotation und LCS-Vergleich

Definition 8.3 (Subgraph-Prüffunktion). Seien $A \in \{0, 1\}^{n_A \times n_A}$, $B \in \{0, 1\}^{n_B \times n_B}$, $n_A \leq n_B$, mit Zeilenkomponenten $\rho_j^A = \sigma_j(A) \bmod 2^{n_A}$ und $\rho_j^B = \sigma_j(B) \bmod 2^{n_B}$.

$$\text{SubgraphCheck}(A, B) = \bigvee_{r=0}^{n_B-1} \bigvee_{s=0}^{n_B-n_A} \left[\text{LCS}(\rho^A, \text{rot}_r(\rho^B)[s : s + n_A]) \geq 2 \right].$$




Abbildung 11: **LCS-Werte pro Rotation** beim Test der drei Motive gegen $\mathcal{N}^+$. Rote Balken: $\text{LCS} \geq 2$ (Subgraph detektiert, Schwelle gestrichelt blau). Alle drei Motive werden in $\mathcal{N}^+$ gefunden; keines in $\mathcal{N}$.

8.3 Laufzeit und Optimalität

Satz 8.4 (Laufzeit $O(n^3)$, Epp 2026). $\text{SubgraphCheck}(A, B)$ ist in Zeit $O(n_B^3)$ berechenbar.

Beweis. (i) Signatur-Berechnung: $O(n_B^2)$. (ii) n_B Rotationsschritte à $O(n_B)$: $O(n_B^2)$. (iii) Pro Rotation bis zu n_B LCS-Vergleiche der Länge n_A : bei fester Motivgröße $n_A = O(1)$ dominiert $O(n_B \cdot n_B \cdot n_A^2) = O(n_B^3)$; für $n_A = n_B$ exakt n_B LCS-Vergleiche à $O(n_B^2)$, also $O(n_B^3)$. Gesamt: $O(n_B^3)$. $\square$

Satz 8.5 (Optimalität unter SETH, Epp 2026). Unter der Strong Exponential Time Hypothesis (SETH) existiert kein Algorithmus, der $\text{SubgraphCheck}(A, B)$ für $n_A = n_B = n$ in Zeit $O(n^{3-\varepsilon})$ löst.

Beweisskizze. Vier Lemmata: (i) Jeder korrekte Algorithmus liest alle n^2 Einträge ($\Omega(n^2)$). (ii) Im Worst Case müssen alle n Rotationen untersucht werden. (iii) Unter SETH kostet LCS der Länge n Zeit $\Omega(n^{2-\varepsilon})$ (Abboud, Backurs, Vassilevska Williams 2015 [6]). (iv) Die n LCS-Berechnungen sind unabhängig und nicht mit $o(n \cdot T_{\text{LCS}}(n))$ durchführbar. Aus (ii)–(iv): $T(n) \geq n \cdot \Omega(n^{2-\varepsilon}) = \Omega(n^{3-\varepsilon})$. $\square$




Abbildung 12: **Komplexitätsvergleich** (log-Skala): Subgraph Algorithmus $O(n^3)$ (blau) vs. naiver Ansatz $O(n! \cdot n^2)$ (rot) vs. untere Schranke $\Omega(n^2)$ (grün). Ab $n = 8$ ist der naive Ansatz $> 10^4$ Mal teurer; ab $n = 10 > 10^6$ Mal. Satz 8.5: $O(n^3)$ ist unter SETH nicht verbesserbar.

9 Netzwerk-induzierte Prädisposition

9.1 Definition und formale Eigenschaften

Definition 9.1 (Netzwerk-induzierte Prädisposition). Für ein GRN $\mathcal{N}$ mit Adjazenzmatrix $A(\mathcal{N})$ und Standardgewichten w_1, w_2, w_3 aus Definition 7.2:

$$G_{\mathcal{N}} = \min \left(1, \sum_{i=1}^3 w_i \cdot \mathbf{1}[\text{SubgraphCheck}(A(M_i), A(\mathcal{N})) = \text{true}] \right) \in [0, 1].$$

Satz 9.2 (Wohldefiniertheit und Messbarkeit). $G_{\mathcal{N}}$ ist wohldefiniert und messbar bezüglich der natürlichen σ -Algebra auf $\{0, 1\}^{n \times n}$.

Beweis. $\text{SubgraphCheck}(\cdot)$ ist korrekt (Injektivität, Lemma 8.2). Die Indikatorfunktion ist $\{0, 1\}$ -wertig und messbar. Gewichtete Summe und Minimum messbarer Funktionen sind messbar. $G_{\mathcal{N}} \in [0, 1]$ per Konstruktion. $\square$

Lemma 9.3 (Monotonie in der Kantenmenge). Sei $E \subseteq E'$ (d. h. $\mathcal{N}' = (V, E')$ durch Kantenzugabe aus $\mathcal{N}$ entstanden). Dann $G_{\mathcal{N}} \leq G_{\mathcal{N}'}$.

Beweis. Es genügt zu zeigen: $\text{SubgraphCheck}(A(M_i), A(\mathcal{N})) = \text{true}$ impliziert dann $\text{SubgraphCheck}(A(M_i), A(\mathcal{N}')) = \text{true}$. Da $E \subseteq E'$: $A(\mathcal{N})_{ij} = 1 \implies A(\mathcal{N}')_{ij} = 1$, also $\rho_j^{\mathcal{N}} \leq \rho_j^{\mathcal{N}'}$ komponentenweise. Stimmen Zeilenkomponenten für ein Matching überein, bleiben sie in $\mathcal{N}'$ erhalten; neue Kanten können zusätzliche Matchings erzeugen. Die LCS-Länge kann daher nicht kleiner werden. $\square$

Korollar 9.4 (Normierung). $G_{\mathcal{N}} = 0 \iff$ kein Motiv in $\mathcal{N}$ detektiert. $G_{\mathcal{N}} = 1 \iff$ alle drei Motive detektiert.




Abbildung 13: **Links: $G_{\mathcal{N}}$ als Funktion der Netzwerkdichte ρ** für 40 synthetische Netzwerke ($n = 6$). Monotonielema 9.3 sichtbar: höhere Dichte führt tendenziell zu höherem $G_{\mathcal{N}}$. Diamant: $\mathcal{N}$ normal ($G = 0.40$); Stern: $\mathcal{N}^+$ Krebs ($G = 1.0$).

Rechts: GSKA-Kurven $P(G_{\mathcal{N}}, S)$. Kritische Stressschwellen S^* für beide Netzwerke (vertikale gepunktete Linien). Für $\mathcal{N}^+$: $S^* \approx 0.071$.

10 Integration: Das N-GSKA-Modell

10.1 Definition und biologische Konsistenz

Definition 10.1 (N-GSKA-Modell). Das *netzwerk-erweiterte GSKA-Modell* setzt $G = G_{\mathcal{N}}$:

$$P_{\mathcal{N}}(S) = P(G_{\mathcal{N}}, S) = \sigma(\alpha G_{\mathcal{N}} + \beta S + \gamma G_{\mathcal{N}} S - \theta).$$

Satz 10.2 (Biologische Konsistenz). Das N-GSKA-Modell erfüllt:

- (i) *Motiv-Monotonie*: $\mathcal{N} \subseteq \mathcal{N}' \implies P_{\mathcal{N}}(S) \leq P_{\mathcal{N}'}(S)$ für alle S .
- (ii) *Reine Stressinduzierbarkeit*: $G_{\mathcal{N}} = 0 \implies P_{\mathcal{N}}(S) = \sigma(\beta S - \theta)$.
- (iii) *Maximale Prädisposition*: $G_{\mathcal{N}} = 1 \implies P_{\mathcal{N}}(S) = P(1, S)$.
- (iv) *Kompensierbarkeit*: Für $G_{\mathcal{N}} < 1$ existiert $S^*(G_{\mathcal{N}}) > 0$ mit $P_{\mathcal{N}}(S) < 0.5$ für alle $S < S^*(G_{\mathcal{N}})$.

Beweis. (i) folgt aus Lemma 9.3 und Satz 4.1. (ii) und (iii) durch direktes Einsetzen. (iv) Aus dem Kompensationstheorem (Satz 4.6): $S^*(G_{\mathcal{N}}) = (\theta - \alpha G_{\mathcal{N}})/(\beta + \gamma G_{\mathcal{N}}) > 0$ für $G_{\mathcal{N}} < \theta/\alpha = 1.125$, also insbesondere für $G_{\mathcal{N}} \leq 1$. $\square$

10.2 Netzwerk-Kompensationstheorem

Satz 10.3 (Netzwerk-Kompensationstheorem). Sei $G_{\mathcal{N}}[*] \in (0, 1)$.

- (i) *Topologische Kompensation*: Gezielte Kantenstreichung aus $\mathcal{N}^*$ senkt $G_{\mathcal{N}}[*]$ und hebt $S^*(G_{\mathcal{N}}[*])$ an (Risikominderung durch Netzwerkrestrukturierung — z. B. durch Kinase-Inhibitoren).
- (ii) *Quantitative Stressschwelle*: Die erforderliche Stresssenkung zur Unterschreitung von $p = 0,5$ ist

$$\Delta S^* = S_{\text{aktuell}} - \frac{\theta - \alpha G_{\mathcal{N}}[*]}{\beta + \gamma G_{\mathcal{N}}[*]}.$$

Beweis. (i) Seien $\mathcal{N}_1 \supseteq \mathcal{N}_2$ (Vereinfachung durch Streichung). Lemma 9.3: $G_{\mathcal{N}_1} \geq G_{\mathcal{N}_2}$. $S^*(G)$ ist strikt fallend in G (Satz 4.4), also $S^*(G_{\mathcal{N}_1}) \leq S^*(G_{\mathcal{N}_2})$: Vereinfachung hebt die Schwelle. (ii) Direkt aus der Formel für S_{krit}^* . $\square$

11 Monte-Carlo-Validierung

Zwei synthetische Populationen ($N = 200$ Netzwerke, $n = 6$ Knoten): *Gesunde Population* ($\rho \sim \mathcal{N}(0,20, 0,15^2)$, spärliche Netzwerke) und *Krebs-Population* ($\rho \sim \mathcal{N}(0,65, 0,15^2)$, dichte Netzwerke). Für jedes Netzwerk wurde $G_{\mathcal{N}}$ mit dem Subgraph Algorithmus berechnet.




Abbildung 14: **Links: Motiv-Erkennungsraten** ($N = 200$). Alle drei Motive werden in der Krebs-Population signifikant häufiger detektiert (bis zu 3-fach für M_1), was die biologische Validität der Motiv-Wahl bestätigt.

Rechts: Verteilung von $G_{\mathcal{N}}$. Die Krebs-Population ist klar nach rechts verschoben (höherer Median), was den qualitativen Unterschied zwischen gesunden und krebsassoziierten Netzwerken quantifiziert.




Abbildung 15: **GSKA-Phasenraum mit Populationspunkten.** Grün: gesunde Population; Rot: Krebs-Population. Die kritische Isokurve $C_{0,5}$ trennt beide Regionen. Die Verschiebung der roten Population in Richtung Ausbruchsregion bestätigt das N-GSKA-Modell empirisch.

12 Gemeinsamer Ausblick

Das GSKA-N Framework eröffnet zahlreiche Forschungsrichtungen, die beide Teile dieser Arbeit weiterentwickeln.

12.1 Dynamische Zeitreihenmodelle

12.1.1 Stochastische Differentialgleichungen für $S(t)$

Das GSKA-Modell kann zeitlich erweitert werden: $S(t)$ evolviert gemäß

$$dS(t) = \mu_S(S, t) dt + \sigma_S(S, t) dW_t$$

(Wiener-Prozess W_t). Die Erstüberschreitungszeit $\tau = \inf\{t : P(G, S(t)) \geq p_{\text{krit}}\}$ definiert dann die Ausbruchszeit als Zufallsvariable. Klassische Überlebenszeitmodelle (Cox-Proportional-Hazards, Weibull) sind Spezialfälle.

12.1.2 Dynamische Netzwerktopologie

In Teil II kann $\mathcal{N}(t)$ als zeitevolvierendes Netzwerk modelliert werden (Barabási-Albert-Wachstum): $G_{\mathcal{N}}(t) = \min(1, \sum_i w_i \cdot \mathbf{1}[\text{SubgraphCheck}(M_i, \mathcal{N}(t))])$. Ausbruch tritt auf, wenn $P_{\mathcal{N}(t)}(S) \geq p_{\text{krit}}$.

12.1.3 Altersabhängige Prädisposition

$G(t) = G_0 \cdot (1 + \delta t)^\kappa$ modelliert epigenetische Drift und altersabhängige Promotor-Aktivierung — eine realistischere Altersrisikokurve.

12.2 Stochastische und gemischte Modelle

12.2.1 Populationsebene

Sei $G \sim \text{Beta}(a_G, b_G)$ in der Population. Die marginale Ausbruchswahrscheinlichkeit

$$\bar{P}(S) = \int_0^1 \sigma(\alpha g + \beta S + \gamma g S - \theta) f_{\text{Beta}}(g; a_G, b_G) dg$$

ist numerisch durch Gauß-Quadratur approximierbar. Populationsgenetische Daten (UK Biobank, TCGA) erlauben empirische Kalibrierung von (a_G, b_G) .

12.2.2 Mixed-Effects-Modelle

Individuelle Zufallseffekte $b_i \sim \mathcal{N}(0, \tau^2)$ erfassen unbeobachtete Heterogenität: $P_i(G_i, S_i) = \sigma(\alpha G_i + \beta S_i + \gamma G_i S_i - \theta + b_i)$.

12.3 Hochdimensionale Erweiterungen

12.3.1 Vektorwertige Prädisposition und Interaktionsmatrix

Polygene Risikoscores $\mathbf{g} \in \mathbb{R}^{d_G}$ und multidimensionale Stressvektoren $\mathbf{s} \in \mathbb{R}^{d_S}$ erlauben

$$P(\mathbf{g}, \mathbf{s}) = \sigma(\mathbf{w}_G^\top \mathbf{g} + \mathbf{w}_S^\top \mathbf{s} + \mathbf{g}^\top \mathbf{A} \mathbf{s} - \theta)$$

mit Interaktionsmatrix $\mathbf{A} \in \mathbb{R}^{d_G \times d_S}$, schätzbar durch LASSO-regularisierte logistische Regression.

12.3.2 Gewichtete und signierte Netzwerke

Der Subgraph Algorithmus behandelt aktuell ungewichtete Graphen. Kanten in GRNs tragen jedoch Aktivierungs-/Inhibitionsstärken. Eine Erweiterung: $\sigma_j^w(A) = \sum_i w_{ij} \cdot r_i + j \cdot 2^n$ mit quantitativem LCS-Matching (Smith-Waterman-Score).

12.3.3 Epigenetische Mediation

Dreistufiges Modell: $E = f(G, S)$ (epigenetischer Zustand als Mediator), $P = \sigma(\alpha_E E + \beta_G G + \beta_S S - \theta)$. Mendelian Randomization schätzt direkte und indirekte Effekte.

12.4 Netzwerkbasierte Erweiterungen

12.4.1 Zelluläre Ausbreitung als Graphenprozess

Auf einem Zellverbandsgraph $\mathcal{G} = (V, E)$ mit lokalen (G_i, S_i) -Werten modelliert ein stochastischer Prozess die klonale Ausbreitung transformierter Zellen — eine Verbindung zur Perkolationstheorie.

12.4.2 Mehrskalige Netzwerkmodelle

$G_{\mathcal{N}}^{\text{multi}} = \lambda_1 G_{\mathcal{N}}^{\text{gen}} + \lambda_2 G_{\mathcal{N}}^{\text{protein}} + \lambda_3 G_{\mathcal{N}}^{\text{gewebe}}$ integriert drei biologische Ebenen. Der Subgraph Algorithmus operiert auf jeder Ebene mit krebstypspezifischen Motiv-Katalogen.

12.4.3 Soziale Netzwerke und Stresskontagion

Psychosozialer Stress breitet sich in sozialen Netzen aus. Diffusionsmodell: $dS_i/dt = \sum_j w_{ij}(S_j - S_i) + \eta_i(t)$. Das GSKA-Modell berechnet daraus individuelle Ausbruchsrisiken — ein bevölkerungsweites Präventionsmodell.

12.5 Maschinelles Lernen und Kausalinferenz

12.5.1 Deep Survival Networks

DeepSurv und ähnliche Architekturen integrieren Genomik, klinische Marker und Lifestyle-Indikatoren. Die Kompensationsstruktur des GSKA-Modells dient als Induktionsbias in der Netzwerkarchitektur.

12.5.2 Graph Neural Networks und Subgraph-Inductive-Bias

Der Subgraph Algorithmus kann als struktureller Inductive Bias in GNNs eingebaut werden: Statt alle paarweisen Knotenbeziehungen zu lernen, fokussiert das GNN auf zyklische Rotationen und LCS-ähnliche Ähnlichkeitsmaße — mit höherer Trainingseffizienz und Interpretierbarkeit.

12.5.3 Kausalmodelle (DAGs)

Im Pearl'schen DAG-Framework unterscheidet sich die Interventionsverteilung $P(Y = 1 \mid do(S = s))$ von der Beobachtungsverteilung $P(Y = 1 \mid S = s)$. Counterfactual Reasoning: „Wie hoch wäre das Risiko von Individuum i bei anderer Lebensumgebung S' ?“ — klinisch entscheidend für personalisierte Prävention.

12.6 Therapeutische und präventive Implikationen

12.6.1 Optimale Interventionsstrategie

Individuelle Stresssenkung $\Delta S_i^* = S_i - S^*(G_i; p_0)$ aus dem Kompensationstheorem; im N-GSKA-Modell: gezielte Kantenstreichung (Kinase-Inhibitor) senkt $G_{\mathcal{N}}$ und hebt S^* an.

12.6.2 Topologische Tumorthherapie

Satz 10.3(i) formalisiert: Inhibitoren, die spezifische Kanten in Signaltransduktionsnetzwerken unterbrechen, können ein Motiv M_i als Subgraph eliminieren und damit $G_{\mathcal{N}}$ senken.

12.6.3 Kosten-Nutzen-Analyse

Optimierungsproblem: $\min_{\Delta S \geq 0} [c_S \cdot \Delta S + c_K \cdot P(G, S - \Delta S)]$ mit Interventionskosten c_S und Krebsfolgekosten c_K — konvexes Problem mit analytischer Lösung im GSKA-Rahmen.

12.6.4 Single-Cell-Kalibrierung

scRNA-seq erlaubt patientenspezifische GRN-Rekonstruktion $\mathcal{N}_i$, woraus $G_{\mathcal{N}_i}$ per Subgraph Algorithmus berechnet wird. Mit gemessenem Allostatic Load Score als S_i ergibt sich eine vollständig individuelle Risikoschätzung $P_{\mathcal{N}_i}(S_i)$.

12.7 Formale Verifikation und Validierung

12.7.1 Statistische Anpassungstests

Hosmer-Lemeshow-Test, ROC-AUC, Brier-Score. Likelihood-Ratio-Test: Ist γ signifikant von Null verschieden?

12.7.2 Formale Verifikation in Lean4

Beweise von Lemma 8.2 (Injektivität), Satz 8.4 (Laufzeit), Satz 4.8 (Konvexität) in Lean4/Isabelle/HOL — insbesondere für sicherheitskritische medizinische Systeme erforderlich.

12.7.3 Parallelisierung des Subgraph Algorithmus

Die n_B Rotationsschritte sind datenparallel und unabhängig. GPU-Implementierung (CUDA/OpenCL) reduziert Laufzeit von $O(n^3)$ auf $O(n^2)$ mit n Threads — essential für humane Protein-Interaktionsnetzwerke ($n > 10^4$).

12.8 Verbindung zur Informationstheorie

Die Shannon-Entropie $H(P) = -P \ln P - (1 - P) \ln(1 - P)$ ist maximal auf $C_{0,5}$, wo auch die Sensitivität maximal ist. Diese Zone höchster Unsicherheit und höchster Interventionswirksamkeit ist die primäre Zielzone für präventive Maßnahmen — sowohl im GSKA-Modell als auch im N-GSKA-Modell, wo sie topologisch durch die Menge der Netzwerke mit $G_{\mathcal{N}} \approx S_{\text{krit}}^{-1}(S_{\text{aktuell}})$ charakterisiert wird.

Literatur

- [1] Epp, S. (2026). *Der Subgraph Algorithmus*. Verfügbar auf <https://gitlab.com/epp-group/subgraph>
- [2] Hanahan, D. & Weinberg, R. A. (2011). Hallmarks of cancer: The next generation. *Cell*, 144(5), 646–674.
- [3] Barabási, A.-L. & Oltvai, Z. N. (2004). Network biology: understanding the cell’s functional organization. *Nature Reviews Genetics*, 5(2), 101–113.
- [4] Lee, T. I. et al. (2002). Transcriptional regulatory networks in *Saccharomyces cerevisiae*. *Science*, 298(5594), 799–804.
- [5] Milo, R. et al. (2002). Network motifs: Simple building blocks of complex networks. *Science*, 298(5594), 824–827.

- [6] Abboud, A., Backurs, A. & Vassilevska Williams, V. (2015). Tight hardness results for LCS and other sequence similarity measures. *FOCS 2015*, IEEE, 59–78.
- [7] Anand, P. et al. (2008). Cancer is a preventable disease that requires major lifestyle changes. *Pharmaceutical Research*, 25(9), 2097–2116.
- [8] McGranahan, N. & Swanton, C. (2017). Clonal heterogeneity and tumor evolution. *Cell*, 168(4), 613–628.
- [9] Tomasetti, C., Li, L. & Vogelstein, B. (2017). Stem cell divisions, somatic mutations, cancer etiology, and cancer prevention. *Science*, 355(6331), 1330–1334.
- [10] Wu, S., Powers, S., Zhu, W. & Bhutkar, A. (2016). Substantial contribution of extrinsic risk factors to cancer development. *Nature*, 529(7584), 43–47.
- [11] Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.
- [12] Cox, D. R. (1972). Regression models and life tables. *Journal of the Royal Statistical Society B*, 34(2), 187–220.
- [13] Cybenko, G. (1989). Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals, and Systems*, 2(4), 303–314.