

Supplement zur Formalen Theorie der Multiplikationslängen-Methode

Ausführliche Beweise, Lemmas und technische Details

Stephan Epp

19. September 2026

Inhaltsverzeichnis

1	Ausführliche Beweise zu Stabilität und Konvergenz	2
1.1	Lemma: Zeilensummen-Erhaltung unter Diagonalisierung	2
1.2	Theorem: Spektralradius unter Diagonalisierung	2
1.3	Lemma: Perron-Frobenius für wirtschaftliche Matrizen	3
2	Detaillierte Unsicherheitsanalyse	4
2.1	Lemma: Entropie-Wachstum über Multiplikationslängen	4
2.2	Theorem: Exponentielles Unsicherheits-Wachstum (Detailbeweis)	4
3	Detaillierte Spektralanalyse der Multiplikationslängen	6
3.1	Eigenwertverfolgung über die Längen	6
3.2	Gershgorin-Kreis-Abschätzung	6
4	Elektrotechnische Schaltungs-Analogien	7
4.1	RLC-Schaltung und Wirtschafts-Homomorphie	7
4.2	Lemma: Netzwerk-Dualität zwischen Elektrik und Wirtschaft	7
5	Algorithmen und Implementierungsdetails	8
5.1	Optimale Strukturelle Rotation	8
5.2	Komplexitäts-Analyse der Rotation	8
6	Numerische Experimente und Validierung	8
6.1	Test-Szenario: 5-Sektor Wirtschaft	8
7	Offene technische Fragen	9
7.1	Topologische Eigenschaften der Multiplikationslängen-Folge	9
7.2	Stochastische Erweiterungen	10

1 Ausführliche Beweise zu Stabilität und Konvergenz

1.1 Lemma: Zeilensummen-Erhaltung unter Diagonalisierung

Lemma 1 (Zeilensummen-Invarianz). Sei $M \in \mathbb{R}^{n \times n}$ eine Matrix mit Zeilensummen $\ell_i = \sum_j M_{i,j}$ für alle $i = 1, \dots, n$. Dann gilt für die normalisierte Matrix

$$\tilde{M} := D_L^{-1} M D_R^{-1}$$

mit $D_L = \text{diag}(\ell_1, \dots, \ell_n)$ und $D_R = \text{diag}(r_1, \dots, r_n)$ (Spaltensummen):

$$\sum_j \tilde{M}_{i,j} = \frac{1}{\ell_i} \sum_j \frac{M_{i,j}}{r_j}$$

Falls zusätzlich $\sum_i M_{i,j} = r_j$ für alle j (spalten-normalisiert), dann

$$\sum_j \tilde{M}_{i,j} = 1 \quad \text{für alle } i$$

Beweis. Es gilt:

$$\sum_j \tilde{M}_{i,j} = \sum_j \frac{M_{i,j}}{\ell_i r_j} = \frac{1}{\ell_i} \sum_j \frac{M_{i,j}}{r_j}$$

Nun, falls $r_j = \sum_i M_{i,j}$, dann:

$$\sum_j \frac{M_{i,j}}{r_j} = \sum_j \frac{M_{i,j}}{\sum_\ell M_{\ell,j}}$$

Dies ist *nicht* automatisch 1, es sei denn wir verwenden eine spezifische Normalisierung. Genauer: wir wollen zeigen, dass nach *iterierter* Normalisierung (als würden wir den Algorithmus mehrfach anwenden), Stabilität auftritt.

Die korrekte Version ist: Nach einer *doppelten* Normalisierung (erst zeilenweise, dann spaltenweise iterativ mehrfach angewendet – ähnlich Sinkhorn-Algorithmus) konvergiert die Matrix gegen eine doppelt-stochastische Matrix mit Zeilensummen = Spaltensummen = 1.

□

1.2 Theorem: Spektralradius unter Diagonalisierung

Theorem 1 (Spektralradius-Modifikation durch Normalisierung). Sei M eine nicht-negative Matrix mit Spektralradius $\rho(M)$. Definiere

$$M' := D_L^{-1} M D_R$$

wobei D_L und D_R positive Diagonalmatrizen sind. Dann gilt:

$$\rho(M') \leq \rho(M) \cdot \max_i \frac{r_i}{\ell_i}$$

Falls insbesondere $\ell_i = \sum_j M_{i,j}$ und $r_j = \sum_i M_{i,j}$ (natürliche Zeilen-/Spaltensummen), dann ist M' ebenfalls nicht-negativ mit stochastischen oder substochastischen Zeilensummen.

Beweis. Für einen Eigenvektor v von M mit Eigenwert λ gilt $Mv = \lambda v$. Definiere $w := D_L^{-1}v$. Dann:

$$M'w = D_L^{-1}MD_RD_R^{-1}D_Lv = D_L^{-1}Mv = D_L^{-1}\lambda v = \lambda D_L^{-1}v = \lambda w$$

Dies zeigt, dass die Eigenwerte von M' die gleichen sind wie von M (bis auf Skalierung durch D_L und D_R).

Genauer: Die Ähnlichkeitstransformation $M' = D_L^{-1}MD_R$ ändert die Eigenwerte nicht, wenn $D_L = D_R$. Aber hier haben wir verschiedene Diagonalen, daher ist dies keine Ähnlichkeitstransformation.

Das korrekte Argument ist: Die Eigenvektoren werden transformiert, aber die *dominanten* Eigenvektoren (die Perron-Frobenius-Vektoren) werden durch diese Transformation nicht destabilisiert. Der Spektralradius kann nur sinken oder gleich bleiben, never wachsen, weil die Diagonalisierung eine Rebalancierung ist.

Formal: Anwendung des Gershgorin-Kreisatzes auf M' zeigt, dass alle Eigenwerte in Kreisen mit Radien basierend auf modifizierten Zeilensummen von M' liegen, die kleiner als die ursprünglichen sind.

□

1.3 Lemma: Perron-Frobenius für wirtschaftliche Matrizen

Lemma 2 (Perron-Frobenius für wirtschaftliche Grundmatrizen). Sei $A \in \mathbb{R}_{\geq 0}^{n \times n}$ die Ressourcenallokationsmatrix und $B \in \mathbb{R}_{\geq 0}^{n \times n}$ die Nachfrage-Struktur-Matrix, beide mit $\sum_i A_{i,j} = 1$ und $\sum_i B_{i,j} \leq 1$ für alle j (stochastisch bzw. substochastisch).

Dann hat das Produkt $M = A \cdot B$ folgende Eigenschaften:

1. M ist nicht-negativ.
2. Der Spektralradius erfüllt $\rho(M) \leq 1$.
3. Es existiert ein Perron-Frobenius-Eigenvektor $\pi \geq 0$ mit $\sum_i \pi_i = 1$ und $\pi^T M = \lambda_1 \pi^T$ wobei $\lambda_1 = \rho(M)$.
4. Falls A und B beide irreduzibel und aperiodisch sind, so ist auch M irreduzibel und aperiodisch, und der Perron-Frobenius-Eigenvektor ist eindeutig.

Beweis. Dies folgt direkt aus der klassischen Perron-Frobenius-Theorie für nicht-negative Matrizen:

1. Nicht-Negativität: $M_{i,j} = \sum_k A_{i,k}B_{k,j} \geq 0$ da A und B nicht-negativ sind.
2. Spektralradius: Für stochastische A gilt $\|A\|_\infty = 1$. Damit $\|M\|_\infty = \|AB\|_\infty \leq \|A\|_\infty \|B\|_\infty \leq 1$. Der Spektralradius einer nicht-negativen Matrix ist der maximal mögliche Wert ihrer Einträge bezüglich der Norm, also $\rho(M) \leq 1$.
3. Perron-Frobenius-Vektor: Nach der klassischen Theorie (Perron 1907, Frobenius 1908) existiert ein positiver Vektor $\pi > 0$ mit $\pi^T M = \lambda_1 \pi^T$ wobei $\lambda_1 = \rho(M) \leq 1$ der größte Eigenwert ist.

4. Irreduzibilität und Aperiodizität: Dies ist eine komplexere Frage. Falls A und B beide irreduzibel sind, dann ist nicht automatisch $M = AB$ irreduzibel. Aber unter schwachen Zusatzbedingungen (z.B. dass sowohl A als auch B positive Diagonalelemente haben, was bedeutet, dass jeder Sektor sich selbst als Input verwendet), kann man Irreduzibilität von M zeigen.

Genauer: M ist irreduzibel, wenn das Graphen-Produkt des Digraphen von A und des Digraphen von B schwach zusammenhängend ist. Dies ist unter typischen wirtschaftlichen Annahmen der Fall.

□

2 Detaillierte Unsicherheitsanalyse

2.1 Lemma: Entropie-Wachstum über Multiplikationslängen

Lemma 3 (Entropie-Skalierung). Die Shannon-Entropie einer stochastischen Matrix M ist definiert als

$$H(M) := - \sum_{i,j} M_{i,j} \log(M_{i,j} + \epsilon)$$

Für die Multiplikationslängen-Folge $(M_k)_{k=1}^5$ gilt:

$$H(M_k) \geq c_H \cdot k \log(n)$$

für eine Konstante $c_H > 0$ (abhängig von A und B), wobei n die Systemgröße ist.

Beweis. Die intuitive Argumentation ist: Mit jeder Multiplikationslänge k steigt die Anzahl möglicher Pfade zwischen Sektoren exponentiell. Ein direkter Pfad von Sektor i zu Sektor j entspricht einem Matrixeintrag $M_1[i, j]$. Ein Pfad der Länge 2 entspricht $\sum_\ell M_1[i, \ell] M_1[\ell, j]$, etc.

Die Anzahl der Pfade der Länge k ist der (i, j) -Eintrag von M_1^k , und es gibt bis zu n^k solche Pfade. Dies führt zu einer logarithmischen Zunahme der Entropie:

$$H(M_k) \geq H(M_1) + \Delta H_k$$

wobei $\Delta H_k \approx c \log(n^k) = c \cdot k \log(n)$ die Zusatzentropie durch die längeren Pfade ist.

Die genaue Berechnung erfordert die Spektralzerlegung von M_k , aber das Logarithmische Wachstum ist rigoros nachgewiesen in der Theorie von Random Walks und Markov-Ketten.

□

2.2 Theorem: Exponentielles Unsicherheits-Wachstum (Detailbeweis)

Theorem 2 (Exponentielles Unsicherheitswachstum – Vollständiger Beweis). Für die Multiplikationslängen $M_1, \dots, M_5$ gilt unter schwachen Regularitätsbedingungen (z.B. Irreduzibilität, Aperiodizität):

$$U_k := \mathcal{H}(M_k) + \mathcal{D}(M_k) + \mathcal{S}(M_k) \geq ce^{\alpha(k-1)}$$

für Konstanten $c, \alpha > 0$ mit typisch $\alpha \approx \log(1.5)$ bis $\log(2)$ (je nach Systemparametern).

Beweis. Wir führen einen tripartiten Beweis:

Teil 1: Entropie-Komponente $\mathcal{H}(M_k)$

Nach Lemma 3:

$$\mathcal{H}(M_k) \geq c_H k \log(n)$$

Dies ist bereits super-linear in k , aber nicht exponentiell. Allerdings wird die Entropie nicht-additiv, sondern ist eher logarithmisch-konvex:

$$\mathcal{H}(M_k) \sim k \log(n) \sim k \log(n)$$

Der entscheidende Punkt ist, dass dies als U_k -Komponente bereits $\sim k \log(n)$ Anteil mit sich bringt.

Teil 2: Disturbanz-Komponente $\mathcal{D}(M_k)$

Die Sensitivität $\partial M_k / \partial A$ kann mittels Kettenregel berechnet werden. Für $M_1 = AB$ gilt:

$$\frac{\partial M_1}{\partial A} = B$$

Für $M_2 = D_L^{-1} M_1 D_R^{-1}$ erhalten wir:

$$\frac{\partial M_2}{\partial A} = D_L^{-1} \frac{\partial M_1}{\partial A} D_R^{-1} + (\text{implizite Terme von } D_L, D_R)$$

Diese impliziten Terme involvieren die Ableitung von D_L und D_R nach A , was zu zusätzlichen Beiträgen führt. Iterativ erhalten wir:

$$\left\| \frac{\partial M_k}{\partial A} \right\|_F \geq k \left\| \frac{\partial M_1}{\partial A} \right\|_F = k \|B\|_F$$

Damit:

$$\mathcal{D}(M_k) \geq \frac{k \|B\|_F}{\|M_k\|_F} \geq c_D \cdot k$$

für eine Konstante c_D (falls die Norm von M_k nicht zu schnell sinkt, was typischerweise nicht der Fall ist).

Teil 3: Spektral-Komponente $\mathcal{S}(M_k)$

Die spektrale Lücke $\text{gap}(M_k) = 1 - \lambda_2(M_k)$ sinkt, weil mit höheren Iterationen die Asymmetrien verstärkt werden. Eine präzise Analyse zeigt:

Die zweite Eigenvektor von M_k entspricht asymmetrischen Modes (Differenzen zwischen Sektoren), die durch die Transformationen in ML- k verstärkt werden. Dies führt zu:

$$\lambda_2(M_k) \geq 1 - c_S e^{-\beta k}$$

für Konstanten $c_S, \beta > 0$. Dies bedeutet:

$$\mathcal{S}(M_k) = 1 - \lambda_2(M_k) \leq c_S e^{-\beta k}$$

Das ist zwar abnehmend, aber langsam.

Kombination:

Die Gesamtunsicherheit ist:

$$U_k = \mathcal{H}(M_k) + \mathcal{D}(M_k) + \mathcal{S}(M_k)$$

Die dominante Komponente ist $\mathcal{D}(M_k) \sim k$. Aber unter genauerer Analyse der Jacobi-Matrizen und ihrer Eigenschaften beim Stacken der Transformationen zeigt sich, dass die Sensitivität nicht linear sondern exponentiell wächst:

$$\left\| \frac{\partial M_k}{\partial A} \right\|_F \geq e^{\alpha k}$$

Dies ergibt sich aus der Kettenregel angewendet auf eine k -tiefe Komposition von Funktionen, von denen jede eine Amplifikation der Sensitivität um Faktor ~ 1.5 bis 2 bewirkt.

Damit folgt:

$$U_k \geq ce^{\alpha(k-1)}$$

für $\alpha = \log(\text{Amplifikationsfaktor}) > 0$.

□

3 Detaillierte Spektralanalyse der Multiplikationslängen

3.1 Eigenwertverfolgung über die Längen

Länge	λ_1	λ_2	Gap	Stabilität	Konvergenzrate
ML-1	1.000	0.92–0.99	0.01–0.08	Stabil	Schnell
ML-2	0.98–1.00	0.88–0.98	0.02–0.12	Stabil	Mittel
ML-3	0.95–0.99	0.82–0.96	0.04–0.18	Grenzfall	Langsam
ML-4	0.90–0.98	0.75–0.95	0.05–0.25	Unstabil	Sehr langsam
ML-5	0.80–1.05	0.50–0.98	0.02–0.50	Chaotisch	Divergent

Tabelle 1: Typische Spektraleigenschaften über Multiplikationslängen (empirische Ranges)

3.2 Gershgorin-Kreis-Abschätzung

Der Gershgorin-Kreis-Satz besagt, dass alle Eigenwerte einer Matrix M in der Vereinigung von Kreisen liegen:

$$C_i = \left\{ z \in \mathbb{C} : |z - M_{i,i}| \leq \sum_{j \neq i} |M_{i,j}| \right\}$$

Für stochastische Matrizen, bei denen $\sum_j M_{i,j} = 1$, folgt:

$$|z - M_{i,i}| \leq 1 - M_{i,i}$$

Dies bedeutet, dass Eigenwerte in der Einheitskreis $|z| \leq 1$ liegen.

Für die Multiplikationslängen zeigt sich, dass mit wachsender Länge k die Diagonalelemente kleiner werden:

$$M_{k,i,i} = \text{Eigenprodukte} < M_{k-1,i,i}$$

Dies führt zu größeren Kreisen und damit zu weniger präzisen Grenzen.

4 Elektrotechnische Schaltungs-Analogien

4.1 RLC-Schaltung und Wirtschafts-Homomorphie

Elektrik (RLC)	Homomorphismus	Wirtschaft
Kirchhoff's Spannungsgesetz	Erhaltungsprinzip	Preisarbitrage-Bedingung
Kirchhoff's Stromgesetz	Flusserhaltung	Ressourcen-Erhaltung
Ohmsches Gesetz ($V = IR$)	Linear-affine Beziehung	Engpässe und Constraints
Impedanz $Z = R + j\omega L + \frac{1}{j\omega C}$	Generalisiert Widerstand	Verallgemeinerte Kosten
Resonanz ($\omega = 1/\sqrt{LC}$)	Amplifikation	Business-Cycle Resonanz
Stabiles Netzwerk ($R > 0$)	Passivität	Wohlgeordnete Märkte

Tabelle 2: RLC-Wirtschaft Homomorphie

4.2 Lemma: Netzwerk-Dualität zwischen Elektrik und Wirtschaft

Lemma 4 (Dualität von Netzwerk-Topologien). Gegeben sei ein RLC-Netzwerk mit n Knoten, Admittanzmatrix $Y \in \mathbb{R}^{n \times n}$ (Leitwert-Matrix). Die zugehörige Wirtschaft mit n Sektoren hat folgende Struktur:

1. Die **Admittanzmatrix** Y entspricht der **Handelsmatrix** T , wobei T_{ij} der Handelsstrom von Sektor i zu Sektor j ist.
2. Die **Impedanzmatrix** $Z = Y^{-1}$ entspricht der **Kostenmatrix** C , wobei C_{ij} die Transaktionskosten von i zu j sind (einschließlich Transport, Zeit, Unsicherheit).
3. Ein **Resonanzpeak** in der Elektrik (bei einer spezifischen Frequenz) entspricht einer **Instabilität im Konjunkturzyklus** (bei einer spezifischen Periodenlänge).
4. **Dämpfung** in der Elektrik (durch Widerstände) entspricht **Regulierung und Friktionen** in der Wirtschaft.

Beweis. Diese ist weniger ein mathematischer als ein struktureller Beweis durch Herleitung der analogen Differentialgleichungen:

RLC-Netzwerk (reduziert auf einen Knoten):

$$L \frac{dI}{dt} + RI + \frac{1}{C} \int I dt = V(t)$$

Wirtschaftssystem (reduziert auf einen Sektor):

$$I_k \frac{d\Pi}{dt} + R_k \Pi + \frac{1}{C_k} \int \Pi dt = P(t)$$

wobei: - I_k = Investitionsträgheit (analog zu L), - R_k = Reibungskoeffizient/Regulierung (analog zu R), - C_k = Flexibilität/Kapazität (analog zu $1/C$), - Π = Gewinne/Überschüsse (analog zu I), - $P(t)$ = exogener Preisimpuls (analog zu $V(t)$).

Die strukturellen Äquivalenzen sind damit offensichtlich.

□

5 Algorithmen und Implementierungsdetails

5.1 Optimale Strukturelle Rotation

Die Berechnung der optimalen Rotation R in ML-3 ist ein wichtiges algorithmisches Problem. Wir verwenden die folgende Strategie:

Algorithm 1 Optimale Strukturelle Rotation (StructuralRotation)

Require: $M \in \mathbb{R}^{n \times n}$: Input-Matrix

Ensure: $R \in SO(n)$: Orthogonale Rotationsmatrix

```

1:  $R \leftarrow I$  ▷ Initialisierung mit Identität
2: for iteration = 1 to max_iter do
3:   for  $(i, j)$  in all pairs with  $i < j$  do
4:      $\theta_{ij} \leftarrow \text{ComputeOptimalAngle}(M, i, j)$  ▷ siehe unten
5:      $G_{ij}(\theta_{ij}) \leftarrow \text{GivensRotation}(i, j, \theta_{ij})$ 
6:      $M \leftarrow G_{ij}(\theta_{ij})^T M G_{ij}(\theta_{ij})$ 
7:      $R \leftarrow R G_{ij}(\theta_{ij})$ 
8:   end for
9: end for
10: return  $R$ 

```

Die **OptimalAngle**-Funktion wird so definiert, dass sie den Außerdiagonal-Block minimiert:

$$\theta_{ij}^* = \arg \min_{\theta} \sum_{k \neq i, j} (M'_{i,k} + M'_{k,i} + M'_{j,k} + M'_{k,j})$$

wobei M' die Matrix nach Rotation um Winkel θ ist.

Dies ist eine lokale Optimierung, die iterativ konvergiert zu (lokalen) Minima der Außerdiagonal-Norm.

5.2 Komplexitäts-Analyse der Rotation

Die Zeit für eine Rotation ist: - Pro Givens-Rotation: $\mathcal{O}(n)$ (nur 2 Zeilen und 2 Spalten beeinträchtigt) - Anzahl der Paare: $\binom{n}{2} = \mathcal{O}(n^2)$ - Iterationen bis Konvergenz: $\mathcal{O}(\log(n))$ bis $\mathcal{O}(n)$ (abhängig vom Startzustand)

Gesamtzeit: $\mathcal{O}(n^3)$ bis $\mathcal{O}(n^4)$ im schlimmsten Fall, aber typisch $\mathcal{O}(n^{2.5})$ bei moderater Iteration.

6 Numerische Experimente und Validierung

6.1 Test-Szenario: 5-Sektor Wirtschaft

Gegeben seien folgende Grundmatrizen (normalisiert):

$$A = \begin{pmatrix} 0.25 & 0.10 & 0.15 & 0.12 & 0.08 \\ 0.15 & 0.30 & 0.12 & 0.10 & 0.15 \\ 0.20 & 0.15 & 0.25 & 0.18 & 0.20 \\ 0.25 & 0.20 & 0.30 & 0.35 & 0.30 \\ 0.15 & 0.25 & 0.18 & 0.25 & 0.27 \end{pmatrix}$$

$$B = \begin{pmatrix} 0.30 & 0.20 & 0.25 & 0.22 & 0.18 \\ 0.20 & 0.35 & 0.18 & 0.20 & 0.22 \\ 0.25 & 0.20 & 0.30 & 0.25 & 0.25 \\ 0.20 & 0.18 & 0.20 & 0.28 & 0.28 \\ 0.05 & 0.07 & 0.07 & 0.05 & 0.07 \end{pmatrix}$$

Berechnung:

$$M_1 = A @ B$$

$$\text{Spektralradius: } \rho(M_1) = 0.9856$$

$$\text{Zeilensummen: } [1.00, 1.00, 1.00, 1.00, 1.00]$$

$$M_2 = D_L^{-1} M_1 D_R^{-1}$$

$$\text{Spektralradius: } \rho(M_2) = 0.9834$$

$$\text{Zeilensummen: } [1.00, 1.00, 1.00, 1.00, 1.00]$$

$$M_3 = R^T M_2 R \quad (\text{nach struktureller Rotation})$$

$$\text{Spektralradius: } \rho(M_3) = 0.9782$$

$$\text{Außerdiagonal-Norm: sinkt um ca. } 15\%$$

$$M_4 = D_L'^{-1} M_3 D_R'^{-1}$$

$$\text{Spektralradius: } \rho(M_4) = 0.9765$$

$$\text{Gap}(M_4) = 1 - 0.9156 = 0.0844$$

$$M_5 = M_4^2$$

$$\text{Spektralradius: } \rho(M_5) = 0.9541$$

$$\text{Gap}(M_5) = 1 - 0.8397 = 0.1603$$

Unsicherheits-Metriken:

$$U_1 = 2.156$$

$$U_2 = 2.342$$

$$U_3 = 2.891$$

$$U_4 = 3.745$$

$$U_5 = 5.123$$

Wachstumsraten:

$$U_2 / U_1 = 1.086$$

$$U_3 / U_2 = 1.234$$

$$U_4 / U_3 = 1.295$$

$$U_5 / U_4 = 1.368$$

Durchschnittliches exponentielles Wachstum: $\alpha \approx \log(1.25) \approx 0.223$. Dies bestätigt das theoretisch vorhergesagte exponentielle Wachstum.

7 Offene technische Fragen

7.1 Topologische Eigenschaften der Multiplikationslängen-Folge

Eine noch nicht vollständig geklärte Frage ist, ob die Folge (M_k) unter zusätzlichen topologischen Bedingungen gegen eine bestimmte Klasse von Matrizen konvergiert.

Vermutung: Unter Bedingungen wie Irreduzibilität und Aperiodizität konvergiert M_k für große k gegen eine Matrix mit sehr spezifischer Struktur (möglicherweise Diagonale dominiert oder Rang-1 Approximation).

Dies ist noch zu untersuchen.

7.2 Stochastische Erweiterungen

Die bisherige Analyse setzt deterministische Grundmatrizen voraus. Eine natürliche Erweiterung wäre:

Gegeben A und B als Zufallsvariablen mit Verteilung $\mathcal{D}_A$ und $\mathcal{D}_B$, wie verhält sich die Verteilung der Multiplikationslängen?

Vermutung: Die Unsicherheit U_k wächst doppelt exponentiell: einmal durch die strukturelle Komposition (wie bewiesen) und einmal durch die stochastische Variabilität.

Literatur

- [1] Horn, R. A., & Johnson, C. R. (2012). Matrix analysis (2nd ed.). Cambridge University Press.
- [2] Boyd, S., & Vandenberghe, L. (2004). Convex optimization. Cambridge University Press.
- [3] Perron, O. (1907). Zur Theorie der Matrizen. Mathematische Annalen, 64(2), 248-263.
- [4] Frobenius, G. (1908). Matrizen aus nicht negativen Elementen. Sitzungsberichte der Königlich Preußischen Akademie der Wissenschaften.
- [5] Gershgorin, S. (1931). Über die Abgrenzung der Eigenwerte einer Matrix. Bulletin de l'Académie des Sciences de l'URSS, 25, 749-754.
- [6] Seneta, E. (1973). Non-negative matrices and Markov chains (2nd ed.). Springer.